

УДК 621.396.41

Н.М. Дубинин, Т.В. Ганджа, М.И. Кочергин, О.В. Филиньюк, В.М. Дмитриев

Разработка интеллектуальной модели диагностики пульмонологических заболеваний на основе нечёткой логики

Рассматривается подход к автоматизации диагностики пульмонологических заболеваний с использованием систем поддержки принятия врачебных решений (СППВР) на основе методов нечёткой логики. Проанализированы существующие отечественные и зарубежные решения в данной области, выявлены основные направления развития. Представлены модель пациента и структура системы управления состоянием, а также реализована интеллектуальная система, позволяющая оценивать вероятность диагноза на основании симптомов. В работе применён метод нечёткого логического вывода, обеспечивающий адаптацию моделей к клиническим данным. Проведён анализ значимости симптомов с использованием коэффициентов корреляции Спирмена. Полученные результаты демонстрируют эффективность использования нечёткой логики в задачах медицинской диагностики.

Ключевые слова: пульмонология, нечеткая логика, ССПВР, модель пациента, постановка диагноза, рекомендации по лечению, система управления состоянием пациента.

DOI: 10.21293/1818-0442-2025-28-2-137-144

В повседневной работе врачам приходится решать множество задач, требующих оперативного и точного реагирования. При определении диагноза и выборе лечения важно учитывать результаты осмотра, индивидуальные характеристики пациента, а также данные лабораторных и инструментальных исследований.

При этом крайне важно своевременно выявлять заболевания и начинать правильное лечение, обеспечивая безопасность пациента. Частичная автоматизация лечебно-диагностического процесса и информационная поддержка специалиста – актуальные задачи, которые призваны снизить нагрузку на врача.

Помощником врача при решении клинических задач, постановки диагноза и выработки дальнейшего лечения для пациента могут стать интеллектуальные и интеллектуализированные информационные системы, реализованные в виде систем поддержки принятия врачебных решений (СППВР), что будет способствовать улучшению качества медицинской помощи, повышению точности диагноза, повышению уровня удовлетворенности пациентов, снижению нагрузки на врачей [1]. СППВР представляет собой специализированную медицинскую информационную платформу, разработанную для содействия медицинским специалистам в решении различных медицинских задач [2]. СППВР интегрируют результаты клинических исследований с данными о конкретном пациенте, что способствует более обоснованному выбору решений для качественного медицинского обслуживания [3].

Существуют два основных типа СППВР:

- системы, основанные на знаниях (экспертные системы);
- системы, основанные на анализе прецедентов, применяющие методы статистической обработки данных или машинного обучения.

Большинство СППВР, основанных на знаниях, состоят из трёх компонентов: базы знаний, механизма логического вывода и коммуникационного модуля [4]. База знаний содержит правила, часто вы-

раженные в продукционной форме (вида ЕСЛИ–ТО). Например, для предупреждения о взаимодействии лекарств система может сработать по правилу: ЕСЛИ назначен препарат «Х» И препарат «Y», ТО предупредить врача.

СППВР, основанные на анализе прецедентов, позволяют находить закономерности в клинических данных без явного программирования правил [5]. Хотя эти системы не объясняют причин своих решений, что ограничивает их использование для постановки диагноза, они оказывают помощь врачам в постдиагностический период, выявляя полезные паттерны [2, 3]. СППВР этой категории могут использовать различные методы, например, машины опорных векторов, нейронные сети и генетические алгоритмы [6].

Обзор исследований

Проведённый анализ исследований российских и зарубежных специалистов в области разработки и применения СППВР [7, 8] позволил определить основные направления работ и применяемые методы. Отечественные исследователи используют метод нечёткой кластеризации [9] и методы нечёткого моделирования в целом [10], вероятностные методы [11] для мониторинга статистической информации о пациентах в условиях неопределенности, для оценки состояния здоровья пациента используются семантические модели представления знаний [12]. Зарубежные исследователи строят СППВР на основе нечётких когнитивных карт [13], методов нечёткой кластеризации [14, 15], системы продукционных правил [16] и др.

Исследователи решают задачи в областях автоматизированной диагностики сердечно-сосудистых заболеваний [17–19], онкологических заболеваний [20], COVID-19 [21] и др.

В области пульмонологии использование, разработка и применение ССПВР находятся на начальной стадии. Большинство заболеваний и способов формального представления диагностической информации и рекомендаций по лечению практически не

затронуты. Автоматизация диагностики в работах исследователей касается классификации рентгеновских снимков лёгких [22–24] или результатов компьютерной томографии [25], акустического анализа дыхания пациентов [26, 27], построения СПВР для анализа рисков при бронхолегочных заболеваниях [28].

Таким образом, проведенный анализ современного состояния исследований показал, что работы в области применения и разработки информационных, в том числе интеллектуальных, технологий для обработки медицинских данных активно ведутся по различным направлениям. Однако методологическая база формирования интеллектуальной поддержки принятия решений при диагностике, лечении и дальнейшем сопровождении пациента в области пульмонологии разработана недостаточно, поэтому данная проблема является фундаментальной, а ее решение – актуальным, научно и практически значимым.

Среди рассмотренных методов в работах отечественных и зарубежных исследователей вызывает интерес метод нечеткой логики для построения нечетких экспертных систем, который сочетает в себе преимущества как СППВР, основанных на знаниях (за счёт использования знаний экспертов в продукционной форме), так и основанных на анализе precedентов – за счёт возможности оптимизации гиперпараметров нечетких моделей на клинических данных. Эта ключевая особенность систем нечеткого логического вывода позволяет осуществить первичную настройку гиперпараметров экспертным методом, а затем оптимизировать полученную модель на экспериментальных данных.

Модель пациента

Рассмотрение взаимодействия врача-пульмонолога с пациентом с позиции системного анализа позволяет выделить и детализировать каждый этап этого сложного процесса. Такое рассмотрение не только углубляет понимание работы врача, но и позволяет оптимизировать процесс лечения для достижения наилучших результатов [29, 30].

Основными показателями (симптомами) состояния пациента в пульмонологии являются: температура, частота дыхания, оксигенация, отхаркивание, хрипение, функция легких, воспалительные маркеры, одышка (диспноэ), цианоз, кашель, сатурация кислорода, гиповентиляция, дыхательные шумы. Значения данных показателей будут входными для разрабатываемой СППВР. Также в результате исследования было выявлено, что основные болезни, которыми подвержены пациенты в пульмонологии и диагностировать, которые может врач-пульмонолог, это хроническая обструктивная болезнь легких (ХОБЛ), бронхиальная астма, пневмония, бронхит, легочная эмболия [31].

В табл. 1 приведена зависимость между показателями (симптомами) и предполагаемыми диагнозами в области пульмонологии. Для показателей приведены возможные численные значения, оценка которых проводилась по шкале Ликерта (градация от 1 до 10, где, например: 1 – отсутствие хрипов, 5 – умеренные хрипы (слушаются при выдохе, не всегда посто-

янные), 10 – сильные хрипы (постоянные, четко слышны при вдохе и выдохе).

Таблица 1
Зависимость показателей и диагнозов

Признаки		БА	Пневмония	Туберкулез
Температура тела	субфебрильная 37–37,9	0	8	9
	фебрильная 38–40	0	10	7
Одышка	если есть	6	7	4
	до 99 уд. / мин	9	2	3
Частота сокращений	свыше 100 уд. / мин	2	9	8
Кровь в мокроте	если есть	1	5	7
Мокрота	слизистая	8	3	6
	слизисто-гнойная	5	7	4
	гнойная	2	8	2
Озоб	если есть	0	7	3
	непродуктивный, сухой	8	8	6
	продуктивный, влажный	4	8	6
Кашель	покашливание	7	4	6

Система поддержки принятия врачебного решения при постановке диагноза

С точки зрения формальной постановки данное исследование решает задачу многоклассовой классификации (multilabel classification), в рамках которой по вектору клинических симптомов пациента требуется определить степень принадлежности к одному или нескольким пульмонологическим заболеваниям: пневмония, туберкулёз, бронхиальная астма (БА).

Обозначим вектор входных признаков пациента как $\mathbf{x} = [x_1, x_2, \dots, x_n]$, где каждый компонент x_i представляет собой наблюдаемый симптом (например, температура тела, кашель, одышка, наличие крови в мокроте и т.д.).

В качестве выходного вектора $\mathbf{y} = [y_1, y_2, y_3] \in [0, 1]$ в третьей степени рассматриваются значения, отражающие степени принадлежности к каждому из целевых состояний: y_1 – пневмония, y_2 – туберкулёз, y_3 – БА. Каждое значение y_j интерпретируется как уровень уверенности (или вероятность) в наличии соответствующего диагноза.

Таким образом, задача сводится к построению отображения $f: R^n \rightarrow [0, 1]$ в третьей степени, которое реализуется на основе системы нечеткого логического вывода типа Мамдани.

Процесс классификации с использованием нечеткой логики реализуется в виде следующей последовательности этапов:

- Инициализация модели: на основании экспертной информации (см. табл. 1) определяются входные переменные, каждая из которых представляется в виде лингвистической переменной с набором термов.

- Задание функций принадлежности: для входных переменных используются функции типа trapmf (трапециевидные) и trimf (треугольные), что обусловлено их интерпретируемостью, простотой параметризации и соответствием экспертным шкалам.

3. Формирование базы правил: создаётся система нечётких правил вида «ЕСЛИ-ТО», устанавливающая логические зависимости между симптомами пациента и диагностическими выводами. Каждое правило отражает экспертное знание о диагностической значимости сочетаний признаков.

4. Фаззификация: входные значения преобразуются в степени принадлежности соответствующим термам через заданные функции принадлежности, формируя нечёткое представление исходных данных.

5. Нечёткий вывод: применяется алгоритм Мамдани, объединяющий активированные правила и определяющий результат по каждому выходному признаку.

6. Дефаззификация: осуществляется методом центра тяжести, в результате чего формируется выходной вектор $y \in [0, 1]$ в третьей степени, значения которого отражают степени принадлежности к каждому из трёх диагнозов (пневмония, туберкулётз, бронхиальная астма).

В данном разделе представлена интеллектуальная система диагностики заболеваний на основе симптомов пациента с использованием нечеткой логики (fuzzy logic). Метод позволяет определить вероятность наличия у пациента одного из трёх заболеваний: пневмония, туберкулётз или бронхиальная астма (БА). Система построена с применением библиотеки fuzzylab. Данный выбор обусловлен рядом практических и методических факторов, актуальных и для задач медицинской диагностики:

- полноценная реализация классического аппарата нечёткой логики, включая задание лингвистических переменных, функций принадлежности, правил вывода и процедур дефаззификации, позволяет напрямую воспроизвести экспертную модель, основанную на медицинских знаниях (см. табл. 1);
- поддержка как треугольных, так и трапециевидных функций принадлежности, что было критически важно для адекватной интерпретации симптомов различной степени выраженности, в том числе с наличием промежуточных или переходных состояний;
- наглядная визуализация графиков принадлежности и логических правил позволяет валидировать модель не только с технической точки зрения, но и в диалоге с медицинскими экспертами;
- интуитивно понятный синтаксис и простота интеграции, что особенно актуально при разработке прототипов экспертных систем;
- лёгкость переноса на другие платформы в случае необходимости масштабирования или включения в состав более сложных программно-диагностических комплексов.

Таким образом, использование FuzzyLab в данном исследовании оправдано с точки зрения функциональности, совместности с экспертной моделью и удобства разработки.

Для написания функций принадлежности вначале необходимо определить входные переменные (табл. 2), а далее сформировать набор производственных правил системы нечёткого логического вывода.

Таблица 2
Выходные переменные для построения графиков принадлежности

Признак (ЛП)	Нечёткое множество	Функция принадлежности
Температура	субфебрильная	Trapmf(35; 36; 37.9; 38,0)
	фебрильная	Trapmf(37.8; 38; 45; 46)
Одышка	слабая	Trapmf(-1, 0, 2, 4)
	средняя	Trapmf(2, 4, 6, 8)
Частота сокращений	сильная	Trapmf(6, 8, 10, 12)
	до 99 уд. / мин.	Trapmf(-1, 0, 99, 100)
Кровь в мокроте	свыше 100 уд./мин.	Trapmf(99, 100, 180, 190)
	отсутствует	Trimf(-1, 0, 1)
Мокрота	присутствует	Trimf(0, 1, 2)
	слизистая	Trimf(-1; 0; 0.5)
Озоб	слизисто-гнойная	Trimf(0; 0.5; 1)
	гнойная	Trimf(0.5; 1, 2)
Кашель	отсутствует	Trimf(-1, 0, 1)
	присутствует	Trimf(0, 1, 2)
	непродуктивный, сухой	Trimf(-1, 0, 5)
	продуктивный, влажный	Trimf(0, 5, 10)
	покашливание	Trimf(5, 10, 12)

При построении функций принадлежности для входных лингвистических переменных использовались трапециевидные (`trapmf`) и треугольные (`trimf`) функции. Такой выбор обусловлен рядом факторов.

Таблица 1, на основе которой построены нечеткие множества, была разработана доктором медицинских наук О.В. Филинюк, обладающим экспертным клиническим опытом. Это придаёт исходным данным характер экспертной системы, где значения симптомов заданы не произвольно, а как результат профессиональной оценки. В таких случаях разумно использовать простые и интерпретируемые формы функций принадлежности, легко согласуемые с экспертными градациями.

Треугольные функции (`trimf`) применялись для описания двух- или трёхуровневых переменных, где значения плавно переходят от одного лингвистического состояния к другому (например, «отсутствует» – «присутствует» или «слизистая» – «слизисто-гнойная» – «гнойная»). Эти функции обеспечивают чёткие границы и хорошо подходят для симптомов с бинарной или дискретной шкалой, особенно в случаях, где необходимо избежать неопределённой зоны плато.

Трапециевидные функции (`trapmf`) использовались там, где симптоматические значения имеют пограничные зоны и области устойчивости, например, температура, частота сокращений, выраженность одышки. Эти функции позволяют учитывать диапазоны значений, равнозначные по медицинскому смыслу, и обеспечивают более реалистичное моделирование клинических градаций.

Таким образом, использование `trimf` и `trapmf` является обоснованным с методологической и практической точки зрения, обеспечивая баланс между простотой реализации, интерпретируемостью

и достоверностью клинического представления симптомов, зафиксированного в экспертной таблице.

Для фазификации каждого входного симптома (например, температура, одышка, кашель и др.) в модели `fis3` с помощью библиотеки FuzzyLab определяются лингвистические переменные и соответствующие функции принадлежности. Пример добавления переменной и её значений:

```
fis3.addInput([35, 42], Name="Температура")
fis3.addMF("Температура", "trapmf",
[35, 36, 37.9, 38.0], Name="Субфебрильная")
fis3.addMF("Температура", "trapmf",
[37.8, 38.0, 45, 46], Name="Фебрильная")
```

Это позволяет системе гибко интерпретировать значения признаков с учётом клинической неопределённости.

По входным переменным (признакам) было сформировано 54 продукционных правила по 18 для каждого диагноза.

Пример продукционных правил системы нечёткого логического вывода:

- Если температура = фебрильная И мокрота = гнойная И кашель = влажный → Пневмония = Да.
- Если одышка сильная, кровь в мокроте присутствует → Туберкулез = Возможно.

Нечёткие правила в программной реализации создаются в виде набора числовых индексов, отражающих конкретные лингвистические термы входных и выходных переменных. Например, следующий набор [1, 0, 0, 0, 0, 0, 1, 1, 3, 1, 2] соответствует конкретной комбинации симптомов и выходов (например, выраженная ЧСС, гнойная мокрота и высокая вероятность пневмонии). Все значения термов интерпретируются через числовые индексы, при этом терм «ДА» соответствует, например, значению 1,0, «вероятно» – 0,8 и т.д. Таким образом, система использует исключительно числовое представление, обеспечивающее корректную работу модели в соответствии с требованиями теории нечётких множеств.

Нечёткий вывод и дефазификация реализованы с использованием функции `evalfis` библиотеки FuzzyLab, которая применяется к сформированной модели `fis3`, основанной на алгоритме Мамдани. На этапе вывода для каждого пациента формируется вектор входных значений на основе исходного датасета, после чего выполняется вызов функции

```
result_raw = f1.evalfis(
    fis3,
    [
        data["Температура"][i],
        data["Одышка"][i],
        data["ЧС"][i],
        data["Кровь в мокроте"][i],
        data["Мокрота"][i],
        data["Озноб"][i],
        data["Кашель"][i],
    ],
    j
)
```

где j – индекс выходной переменной (например пневмония, БА, туберкулёз).

Результатом является структура, содержащая числовое значение выходной переменной. В зависимости от формата возвращаемого объекта производится выборка конкретного значения

```
result = result_raw[1][1] if
isinstance(result_raw, tuple) else
result_raw[0][2].
```

Это значение интерпретируется как степень принадлежности (в нормализованном диапазоне, например, [0, 1]) к соответствующему диагнозу, определённому по выходной лингвистической переменной (например, «БА» или «пневмония»). Такой подход обеспечивает автоматизированную числовую оценку состояния пациента по входным симптомам с учётом неопределённости и экспертных правил, заданных в модели.

Фрагмент исходных данных, приведённый в табл. 3, включает как входные признаки (например, температура, одышка и др.), так и выходные переменные – диагнозы: «пневмония», «туберкулез», «БА». Эти данные были взяты из открытого клинического датасета и использовались исключительно для оценки корректности работы разработанной модели.

Диагнозы не подавались на вход модели и не использовались в процессе логического вывода. Вместо этого они применялись как истинные значения (*ground truth*) для сопоставления с результатами нечёткой диагностики. Такой подход позволяет объективно оценить точность и адекватность предложенного метода на реальных клинических данных с помощью расчёта метрик (accuracy, precision, recall, F1-score) и построения матрицы ошибок.

Таблица 3
Фрагмент исходных данных для работы модели

№	Температура	Одышка	ЧС	Кровь в мокроте	Мокрота	Озноб	Кашель	Пневмония	Туберкулез	БА
0	36	5	80	0	1	0	5	0	0	1
1	36	5	80	0	1	0	5	0	0	1
2	36	5	80	0	1	0	0	0	0	1
3	36	5	80	0	1	0	5	0	0	1
4	36	0	80	0	1	0	0	0	0	1

С помощью коэффициента ранговой корреляции Спирмена проводится анализ зависимости между каждым симптомом и диагнозом (рис. 1). Это позволяет определить, насколько сильно тот или иной признак влияет на вероятность каждого заболевания.

Интерпретация коэффициента:

- близко к +1 → сильная положительная связь;
- близко к -1 → сильная отрицательная связь;
- около 0 → слабая или отсутствующая связь.

На рис. 2 представлена матрица ошибок для задачи классификации диагноза «пневмония».

Видно, что модель предсказывает положительный результат (наличие пневмонии) абсолютно для всех пациентов независимо от их реального состояния. В результате все 120 случаев пневмонии были правильно распознаны (true positive), однако 120 па-

циентов без заболевания ошибочно отнесены к больным (false positive), а случаев верного отрицательного ответа (true negative) модель не выдала вовсе. Таким образом, полнота (Recall) достигает 1,0, т.е. модель не пропускает ни одного больного, что критически важно в медицинских задачах, но точность (Precision) составляет 0,5, что указывает на половину из общего числа ложных срабатываний. Общая точность (Accuracy) – 0,5, гармоническое среднее между точностью (precision) и полнотой (recall) равна 0,667.

Коэффициент ранговой корреляции Спирмена: симптомы - диагнозы

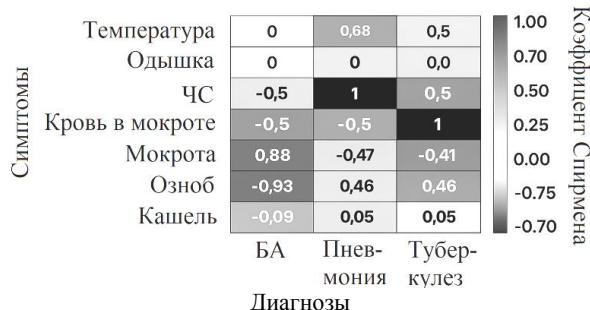


Рис. 1. Коэффициенты ранговой корреляции Спирмена

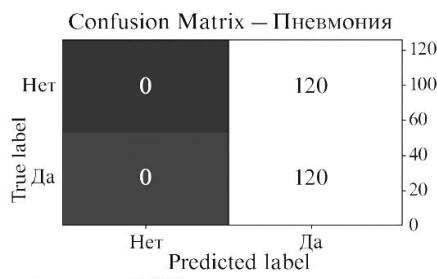


Рис. 2. Матрица ошибок для задачи классификации диагноза «пневмония»

Такой результат свидетельствует о перекосе модели в сторону положительного класса, что может быть связано с дисбалансом в обучающей выборке или отсутствием достаточного числа примеров отрицательного класса. Для повышения эффективности диагностической модели было принято решение о сокращении числа входных признаков (симптомов) с целью улучшения различия между пациентами с наличием и отсутствием заболевания.

Такое решение обусловлено анализом исходной выборки, включающей данные по 240 пациентам, в которой наблюдается значительное количество симптомов с дублирующимися или схожими значениями. Это приводит к информационной избыточности и снижает способность модели к адекватному обобщению, что, в свою очередь, способствует смещению предсказаний в сто-рону положительного класса. Уменьшение размерности входного пространства позволяет устраниТЬ симптомы с низкой дискриминативной способностью, снизить уровень переобучения и повысить точность классификации. Такая оптимизация признакового пространства приведёт к улуч-

шению ключевых метрик качества модели, включая точность постановки диагноза (precision) и гармоническое среднее между точностью и полнотой (F1-мера). Результаты изменений представлены на рис. 3.

На представленной матрице ошибок показаны результаты классификации диагноза «Пневмония» после оптимизации признакового пространства за счёт исключения повторяющихся и избыточных симптомов. По сравнению с предыдущей моделью метрики значительно улучшились: точность классификации (Accuracy) увеличилась до 0,738, F1-мера возросла до 0,792, при сохранении полноты (Recall) на уровне 1,0, что свидетельствует об успешном выявлении всех пациентов с диагнозом. Также улучшилась точность (Precision) – с 0,5 до 0,656, т.е. больше 3/5 предсказаний «пневмония» действительно оказались верными.

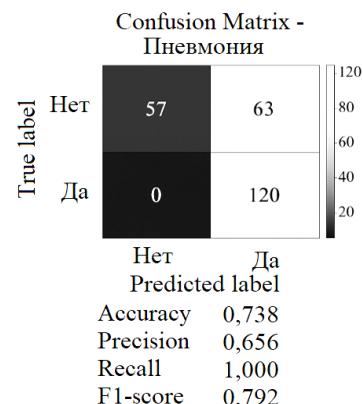


Рис. 3. Обновленная матрица ошибок для задачи классификации диагноза «пневмония»

Тем не менее часть ошибок сохраняется: 63 здоровых пациентов были ошибочно классифицированы как больные, что обусловлено особенностями исходной выборки. Дело в том, что в выборке наблюдается большое количество симптомов с одинаковыми или малодифференцируемыми значениями, что существенно ограничивает обучающую способность модели. При таком ограниченном разнообразии признаков модель испытывает трудности при обучении надёжных различий между классами, что особенно важно в задачах медицинской диагностики. При этом необходимо отметить отсутствие в рассматриваемой выборке данных по ряду признаков, которые во врачебной практике являются значимыми (например, аускультативная картина, результаты рентген-диагностики, результаты анализов крови), что, несомненно, негативно влияет на точность работы модели.

Для дальнейшего повышения качества классификации планируется:

- использовать отбор наиболее значимых признаков на основе статистических и корреляционных критериев;
- применить методы балансировки классов, чтобы уменьшить влияние перекоса на положительный класс;
- расширить обучающую выборку за счёт дополнительных, клинически релевантных данных.

Таким образом, оптимизация признакового пространства уже позволила значительно повысить пока-

затели качества, а дальнейшая работа над структурой данных и архитектурой модели обеспечит ещё более точные и интерпретируемые результаты.

Заключение

Проведенное исследование подтверждает высокую эффективность применения нечёткой логики для построения систем поддержки принятия врачебных решений в области пульмонологии. Представленная модель позволяет учитывать экспертные знания и клинические данные, обеспечивая постановку диагноза. Система демонстрирует устойчивость к неполноте информации и неопределённости симптомов, что особенно актуально в условиях реальной клинической практики. Дальнейшее развитие представленной методологии связано с расширением базы данных, интеграцией методов машинного обучения и повышением автоматизации диагностического процесса.

Литература

1. Stivaros S.M. Decision support systems for clinical radiological practice—towards the next generation / S.M. Stivaros, A. Gledson, G. Nenadic, X.-J. Zeng, J. Keane, A. Jackson // British Journal of Radiology. – 2010. – Vol. 83, № 995. – С. 904–914.
2. Berner E.S. (ed.). Clinical decision support systems. – New York: Springer Publ., 2007. – 270 р.
3. Khosla Vinod. Technology will replace 80% of what doctors do [Электронный ресурс]. – URL: <https://web.archive.org/web/20130328173118/http://tech.fortune.cnn.com/2012/12/04/technology-doctors-khosla/> (дата обращения: 01.02.2025).
4. Dehghani Soufi M. Decision support system for triage management: A hybrid approach using rule-based reasoning and fuzzy logic / M. Dehghani Soufi, T. Samad-Soltani, S. Shams Vahdati, P. Rezaei-Hachesu // International Journal of Medical Informatics. – 2018. – Vol. 114. – Р. 35–44.
5. Tanveer Syeda-Mahmood plenary talk: The Role of Machine Learning in Clinical Decision Support // SPIE Newsroom. – 2015 [Электронный ресурс]. – URL: https://www.spie.org/news/mi-plenary_landing/mi-plenary_syeda-mahmood (дата обращения: 01.02.2025).
6. Wagholar K. Modeling Paradigms for Medical Diagnostic Decision Support: A Survey and Future Direction / K. Wagholar, V. Sundararajan, A. Deshpande // Journal of Medical Systems. – 2012. – Vol. 36, No. 5. – Р. 3029–3049.
7. Демушкина К.М. Обзор методов проектирования систем поддержки принятия врачебных решений / К.М. Демушкина, М.О. Демушкин, А.В. Кузьмин // Модели, системы, сети в экономике, технике, природе и обществе. – 2022. – № 42. – С. 75–89.
8. Гришунов С.С. К вопросу о применении методов машинного обучения для решения задачи диагностики болезней сердца / С.С. Гришунов, А.В. Козина, Ю.С. Носова // Электронный журнал: наука, техника и образование. – 2018. – № СВ2 (20). – С. 37–46 [Электронный ресурс]. – URL: <http://nto-journal.ru/uploads/articles/2b705aada13b2f9b547ab0bf72ef1744.pdf> (дата обращения: 01.02.2025).
9. Павлова А.И. Применение алгоритмов машинного обучения для прогнозирования заболеваний сердца // Сибирский журнал естественных наук и сельского хозяйства. – 2023. – Т. 15, № 3. – С. 475–496.
10. Уткин Л.В. Обзор методов объяснения и интерпретации принятия решений в интеллектуальных системах диагностики онкологических заболеваний / Л.В. Уткин, А.А. Мелло, М.С. Ковалев, Э.М. Касимов // Искусственный интеллект и принятие решений. – 2020. – № 3. – С. 55–65.
11. Рунова К.В. Классификация сердечно-сосудистых заболеваний с помощью инструментальных методов обработки информации на основе различных методов машинного обучения / К.В. Рунова, А.А. Юрин // Вестник Казанского технологического ун-та. – 2019. – Т. 22, № 3. – С. 45–53.
12. Козлов В.В. Система поддержки принятия решений при диагностике заболеваний лёгких / В.В. Козлов, А.В. Козлов // Мир науки без границ. – 2011. – Т. 18, № 1. – С. 187–188.
13. Костин К.А. Классификация патологий диссеминированного туберкулёза лёгких с помощью методов машинного обучения / К.А. Костин, Т.С. Ламонова // Сборник избр. статей научной сессии ТУСУР, Томск, 16–18 мая 2018 г.: в 3 ч. – Томск: В-Спектр, 2018/ – Ч. 3. – С. 129–132.
14. Лаптева Е.А. Применение технологии «нейронных сетей» для выявления и мониторинга аускультативных феноменов при диагностике заболеваний органов дыхания / Е.А. Лаптева, И.В. Коваленко, А.Н. Лаптев и др. // Журнал Гродненского гос. мед. ун-та. – 2020. – Т. 18, № 3. – С. 230–235.
15. Юсупова Н.И. Снижение рисков при использовании машинного обучения в диагностике бронхолегочных заболеваний / Н.И. Юсупова, М.Р. Богданов, О.Н. Сметанина // Искусственный интеллект и принятие решений. – 2023. – № 1. – С. 42–54.
16. Бояринцев Л.А. Разработка системы ранней диагностики внебольничной пневмонии, Covid-19, туберкулеза и других заболеваний легких с использованием искусственного интеллекта / Л.А. Бояринцев, А.В. Трофименко, С.В. Стебельцов и др. // Состояние и перспективы развития современной науки по направлению «Биотехнические системы и технологии»: сборник статей III Всерос. науч.-техн. конф. – Анапа: ФГАУ ВИТ «ЭРА», 2021. – С. 45–49.
17. Юсупова Н.И. Формализация этапов риск-анализа в СППР с учетом оценок клинических рисков при бронхолегочных заболеваниях / Н.И. Юсупова, О.С. Нургаянова, Р.Х. Зулкарнеев // Системная инженерия и информационные технологии. – 2023. – Т. 5, № 1(10). – С. 11–24. DOI: 10.54708/2658-5014-SIT-2023-no1-p11.
18. Юсупова Н.И. Снижение рисков при использовании машинного обучения в диагностике бронхолегочных заболеваний / Н.И. Юсупова, М.Р. Богданов, О.Н. Сметанина // Искусственный интеллект и принятие решений. – 2023. – № 1. – С. 42–54. DOI: 10.14357/20718594230105.
19. Ходашинский И.А. Метод нахождения подмножеств согласованных признаков при прогнозировании эффективности реабилитации пациентов после перенесенной коронавирусной инфекции / И.А. Ходашинский, И.Н. Смирнова, М.Б. Бардамова, К.С. Сарин и др. // Сибирский журнал клинической и экспериментальной медицины. – 2023. – Т. 38, № 4. – С. 270–279.
20. Гусев А.В. Машинное обучение на лабораторных данных для прогнозирования заболеваний / А.В. Гусев, Р.Э. Новицкий, А.А. Ившин, А.А. Алексеев // Фармакоэкономика. Современная фармакоэкономика и фармакоэпидемиология. – 2021. – Т. 14, № 4. – С. 581–592.
21. Мазитова Н.Н. Применение системного подхода в диагностике профессиональных заболеваний органов дыхания / Н.Н. Мазитова, З.М. Берхеева // Общественное здоровье и здравоохранение. – 2013. – Т. 53, № 3. – С. 20–25.
22. Теория и системы управления: учеб.-метод. пособие / сост.: В.Н. Лазарев, Т.А. Шулленкова. – Ульяновск: УлГТУ, 2016. – 165 с.
23. Пульмонология – энциклопедия [Электронный ресурс]. – URL: <https://medportal.ru/enc/pulmonology> (дата обращения: 23.02.2025).
24. Rajpurkar P. Radiologist-Level Pneumonia Detection on Chest X-Rays with Deep Learning / P. Rajpurkar, J. Irvin, K. Zhu et al. // arXiv preprint. – 2017 [Электронный ресурс]. – URL: <https://arxiv.org/abs/1711.05225> (дата обращения: 01.03.2025).
25. Яровой А.Н. Возможности компьютерной томографии в диагностике заболеваний легких / А.Н. Яровой, И.М. Белоусова // Лучевая диагностика и терапия. – 2020. – № 2. – С. 31–36.

26. Moussavi Z. Respiratory sounds analysis as a diagnostic tool // Medical & Biological Engineering & Computing. – 2006. – Vol. 44, No. 10. – P. 931–933.
27. Шайдурова И.А. Акустический анализ дыхательных шумов при заболеваниях легких / И.А. Шайдурова, Т.В. Вавилова, П.М. Котляров // Современные технологии в медицине. – 2021. – № 4. – С. 115–121.
28. Юсупова Н.И. Формализация этапов риск-анализа в СППР с учетом оценок клинических рисков при бронхолегочных заболеваниях / Н.И. Юсупова, О.С. Нургаянова, Р.Х. Зулкарнеев // Системная инженерия и информационные технологии. – 2023. – Т. 5, № 1(10). – С. 11–24.
29. Трошин С.А. Системный анализ взаимодействия врача и пациента в контексте цифровизации здравоохранения / С.А. Трошин, М.А. Малышев // Менеджмент в здравоохранении. – 2021. – № 3. – С. 32–39.
30. Егорова И.А. Формализация модели управления состоянием пациента в медицинских информационных системах / И.А. Егорова, С.М. Красильникова // Информационные технологии в медицине. – 2020. – № 1. – С. 45–50.
31. Пульмонология – основные заболевания [Электронный ресурс]. – URL: <https://29gkb.ru/about/branches/therapeutic/pulmonology/treateddiseases> (дата обращения: 03.06.2025).

Дубинин Никита Максимович

Аспирант каф. компьютерных систем
в управлении и проектировании (КСУП),
Томского государственного университета
систем управления и радиоэлектроники (ТУСУР)
Ленина пр-т, 40, г. Томск, Россия, 634050
Тел.: +7-929-373-04-98
Эл. почта: nikita.d@inbox.ru

Ганджа Тарас Викторович

Д-р техн. наук, проф. КСУП ТУСУРа
Ленина пр-т, 40, г. Томск, Россия, 634050
ORCID: 0000-0002-4996-8114
Тел.: +7-913-846-11-77
Эл. почта: gandgatv@gmail.com

Кочергин Максим Игоревич

Канд. техн. наук, доцент КСУП ТУСУРа
Ленина пр-т, 40, г. Томск, Россия, 634050
Тел.: +7-913-109-76-24
Эл. почта: maksim.i.kochergin@tusur.ru

Филиниuk Ольга Владимировна

Д-р мед. наук, проф., зав. каф. фтизиатрии
и пульмонологии ФГБОУ ВО СибГМУ
Московский тракт, 2, г. Томск, Россия, 634055
Тел.: +7-913-857-24-15
Эл. почта: filinyk.ov@ssmu.ru

Дмитриев Вячеслав Михайлович

Д-р техн. наук, проф. каф. КСУП ТУСУРа
Ленина пр-т, 40, г. Томск, Россия, 634050
ORCID: 0000-0002-1089-6993
Тел.: +7 (382-2) 41-47-17
Эл. почта: dmitriewvm@gmail.com

Поступила в редакцию: 10.06.2025.

Принята к публикации: 01.08.2025.

Dubinin N.M., Gandga T.V., Kochergin M.I., Filinyuk O.V., Dmitriev V.M.

Development of an intelligent diagnostic model for pulmonological diseases based on fuzzy logic

This article explores an approach to automating the diagnosis of pulmonary diseases using clinical decision support systems (CDSS) based on fuzzy logic methods. Both domestic and international solutions in this area are analyzed, and key development directions are identified. A patient model and a health status control system architecture are presented. An intelligent system is implemented to estimate the likelihood of a diagnosis based on symptoms. The study employs a fuzzy inference method to adapt the models to clinical data. The significance of symptoms is analyzed using Spearman rank correlation coefficients. The results obtained demonstrate the effectiveness of applying fuzzy logic in medical diagnostics.

Keywords: pulmonology, fuzzy logic, SPVR, patient model, diagnosis, treatment recommendations, patient condition management system.

DOI: 10.21293/1818-0442-2025-28-2-137-144

References

1. Stivaros S.M., Gledson G., Nenadic G., Zeng X.-J., Keane J., Jackson A. Decision support systems for clinical radiological practice – towards the next generation. *British Journal of Radiology*, 2010, vol. 83, no. 995, pp. 904–914.
2. Berner E.S. (ed.). Clinical decision support systems. New York, Springer Publ., 2007, 270 p.
3. Khosla Vinod. Technology will replace 80% of what doctors do. Available at: <https://web.archive.org/web/20130328173118/http://tech.fortune.cnn.com/2012/12/04/technology-doctors-khosla/> (Accessed: 1 February 2025).
4. Dehghani Soufi M., Samad-Soltani T., Shams Vahdati S., Rezaei-Hachesu P. Decision support system for triage management: A hybrid approach using rule-based reasoning and fuzzy logic. *International Journal of Medical Informatics*, 2018, vol. 114, pp. 35–44.
5. Tanveer Syeda-Mahmood. The Role of Machine Learning in Clinical Decision Support. *SPIE Newsroom*, 2015. Available at: URL: https://www.spie.org/news/mi-plenary_landing/mi-plenary_syeda-mahmood (Accessed: 1 February 2025).
6. Wagholicar K., Sundararajan V., Deshpande A. Modeling Paradigms for Medical Diagnostic Decision Support: A Survey and Future Direction. *Journal of Medical Systems*, 2012, vol. 36, no. 5, pp. 3029–3049.
7. Demushkina K.M., Demushkin M.O., Kuzmin A.V. [Review of methods for designing medical decision support systems]. *Models, systems, networks in economics, technology, nature and society*, 2022, no. 42, pp. 75–89 (in Russ.).
8. Grishunov S.S., Kozina A.V., Nosova Yu.S. [On the issue of applying machine learning methods to solve the problem of diagnosing heart diseases]. *Electronic journal: Science, Technology and Education*, 2018, no. SV2/2018 (20), pp. 37–46. Available at: URL: <http://nto-journal.ru/uploads/articles/2b705aada13b2f9b547ab0bf72ef1744.pdf> (Accessed: 1 February 2025).
9. Pavlova A.I. [Application of machine learning algorithms for predicting heart diseases]. *Siberian Journal of Natural Sciences and Agriculture*, 2023, vol. 15, no. 3, pp. 475–496 (in Russ.).
10. Utkin L.V., Mehldau A.A., Kovalev M.S. and Kasmov E.M. [Review of methods of explanation and interpretation of decision-making in intelligent systems for the diagnosis of oncological diseases]. *Artificial intelligence and decision-making*, 2020, no. 3, pp. 55–65 (in Russ.).
11. Runova K.V., Yurin A.A. [Classification of cardiovascular diseases using instrumental methods of information

- processing based on various machine learning methods]. *Bulletin of Kazan Technological University*, 2019, vol. 22, no. 3, pp. 45–53 (in Russ.).
12. Kozlov V.V., Kozlov A.V. [Decision support system for the diagnosis of lung diseases]. *The world of science without borders*, 2011, vol. 18, no. 1, pp. 187–188 (in Russ.).
 13. Kostin K.A. Lamonova T.S. *Klassifikaciya patologij disseminirovannogo tuberkulyoza lyogikh s pomoshch'yu metodov mashinnogo obucheniya* [Classification of pathologies of disseminated pulmonary tuberculosis using machine learning methods]. *Collection of selected articles of the TUSUR Scientific Session*, Tomsk, May 16–18, 2018, in 3 parts, Tomsk, V-Spectr, 2018, part 3, pp. 129–132 (in Russ.).
 14. Lapteva E.A., Kovalenko I.V., Laptev A.N. et al. [The use of «neural network» technology for the detection and monitoring of auscultation phenomena in the diagnosis of respiratory diseases]. *Journal of the Grodno State Medical University*. 2020, vol. 18, no. 3, pp. 230–235 (in Russ.).
 15. Yusupova N.I., Bogdanov M.R., Smetanina O.N. [Reducing risks when using machine learning in the diagnosis of bronchopulmonary diseases]. *Artificial intelligence and decision-making*, 2023, no. 1, pp. 42–54 (in Russ.).
 16. Boyarintsev L.A. Trofimenco A.V., Stebelsov S.V. et al. *Razrabotka sistemy rannej diagnostiki vnebol'nichnoj pnevmonii, covid-19, tuberkuleza i drugikh zabolovanij legikh s ispol'zovaniem iskusstvennogo intellekta* [Development of a system for early diagnosis of community-acquired pneumonia, COVID-19, tuberculosis and other lung diseases using artificial intelligence]. *Proceedings of II All-Russian scientific and technical conference «State and prospects of development of modern science in the field of «biotechnical systems and technologies»*, Anapa, FGAU VIT «ERA», 2021, pp. 45–49 (in Russ.).
 17. Yusupova, N.I., Nurgayanova O.S., Zulkarneev R.H. [Formalization of the stages of risk analysis in SPD taking into account clinical risk assessments in bronchopulmonary diseases]. *System engineering and information technologies*, 2023, vol. 5, no. 1(10), pp. 11–24. DOI: 10.54708/2658-5014-SIIT-2023-no1-p11 (in Russ.).
 18. Yusupova N.I., Bogdanov M.R., Smetanina O.N. [Risk reduction using machine learning in the diagnosis of bronchopulmonary diseases]. *Artificial intelligence and decision-making*, 2023, no. 1, pp. 42–54. DOI 10.14357/2071859 4230105 (in Russ.).
 19. Khodashinsky I.A., Smirnova I.N., Bardanova M.B., Sarin K.S. et al. [A method for finding subsets of consistent signs in predicting the effectiveness of rehabilitation of patients after coronavirus infection]. *Siberian Journal of Clinical and Experimental Medicine*, 2023, vol. 38, no. 4, pp. 270–279. (in Russ.).
 20. Gusev A.V. Novitsky R.E., Ivshin A.A., Alekseev A.A. [Machine learning on laboratory data for disease prediction]. *Pharmacoeconomics. Modern pharmacoeconomics and pharmacoepidemiology*, 2021, vol. 14, no. 4, pp. 581–592 (in Russ.).
 21. Mazitova N.N., Berheeva Z.M. [Application of a systematic approach in the diagnosis of occupational diseases of respiratory organs]. *Public health and healthcare*, 2013, vol. 53, no. 3, pp. 20–25 (in Russ.).
 22. Lazarev V.N. and Shulenkova T.A. *Teoriya i sistemy upravleniya: uchebno-metodicheskoe posobie* [Theory and control systems: a teaching aid]. Ulyanovsk, UISTU, 2022, 168 p. (in Russ.).
 23. *Pulmonology – encyclopedia*. Available at: <https://medportal.ru/enc/pulmonology> (Accessed: 23 February 2025) (in Russ.).
 24. Rajpurkar P. Irvin J., Zhu K., et al. Radiologist-Level Pneumonia Detection on Chest X-Rays with Deep Learning. *arXiv preprint*, 2017. Available at: <https://arxiv.org/abs/1711.05225> (Accessed: 1 March 2025).
 25. Yarovoy A.N., Belousova I.M. [The possibilities of computed tomography in the diagnosis of lung diseases]. *Radiation diagnostics and therapy*, 2020, no. 2, pp. 31–36 (in Russ.).
 26. Moussavi Z. Respiratory sounds analysis as a diagnostic tool. *Medical & Biological Engineering & Computing*, 2006, vol. 44, no. 10, pp. 931–933.
 27. Shaidurova I.A., Vavilova T.V., Kotlyarov P.M. [Acoustic analysis of respiratory noises in lung diseases]. *Modern technologies in medicine*, 2021, no. 4, pp. 115–121 (in Russ.).
 28. Yusupova N.I., Nurgayanova O.S., Zulkarneev R.Kh. [Formalization of the stages of risk analysis in SPD, taking into account clinical risk assessments for bronchopulmonary diseases]. *System engineering and information technology*, 2023, vol. 5, no. 1(10), pp. 11–24 (in Russ.).
 29. Troshin S.A., Malyshev M.A. [System analysis of doctor-patient interaction in the context of digitalization of healthcare]. *Management in healthcare*, 2021, no. 3, pp. 32–39 (in Russ.).
 30. Egorova I.A., Krasilnikova S.M. [Formalization of the patient's condition management model in medical information systems]. *Information technologies in medicine*, 2020, no. 1, pp. 45–50 (in Russ.).
 31. *Pulmonology – the main diseases*. Available at: <https://29gkb.ru/about/branches/therapeutic/pulmonology/treatdiseases> (Accessed: 3 June 2025) (in Russ.).
-
- Nikita M. Dubinin**
Postgraduate student, Department of Computer Control and Design Systems (CCDS), Tomsk State University of Control Systems and Radioelectronics (TUSUR)
40, Lenin pr., Tomsk, Russia, 634050
Phone: +7-929-373-04-98
Email: nikita.d@inbox.ru
- Taras V. Gandzha**
Doctor of Science in Engineering, Professor,
Department of CCDS, TUSUR
40, Lenin pr., Tomsk, Russia, 634050
ORCID: 0000-0002-4996-8114
Phone: +7-913-846-11-77
Email: gandgatv@gmail.com
- Maxim I. Kochergin**
Candidate of Engineering Sciences, Associate Professor,
Department of CCDS, TUSUR
40, Lenin pr., Tomsk, Russia, 634050
Phone: +7-913-109-76-24
Email: maksim.i.kochergin@tusur.ru
- Olga V. Filinyuk**
Doctor of Medical Sciences, Professor,
Head of the Department of Phthisiology and Pulmonology,
Federal State Budgetary Educational Institution of Higher Education Siberian State Medical University
2, Moskovskiy trakt, Tomsk, Russia, 634055
Phone: +7-913-857-24-15
Email: filinyuk.ov@ssmu.ru
- Vyacheslav M. Dmitriev**
Doctor of Science in Engineering, Professor,
Department of CCDS, TUSUR
40, Lenin pr., Tomsk, Russia, 634050
ORCID: 0000-0002-1089-6993
Phone: +7 (382-2) 41-47-17
Email: dmitriewvm@gmail.com

Received: 10.06.2025.

Accepted: 01.08.2025.