

RAG, Fine-Tuning

Assistant LLM

Assistant LLM (Instruction LLM) — LLM, обученная на инструкциях, на основе которых она дает ответы на любые вопросы. Таких моделей довольно много — можно подобрать себе наиболее подходящую (открытую или коммерческую), например, LLama, Mixtral, GPT4.

Адаптация LLM под свои нужды

- Prompt Engineering
- RAG
- Fine-tuning

Prompt Engineering

Prompting — набор техник и приемов для подачи специальных инструкций в LLM так, чтобы она отвечала определенным образом. Например, инструкция для обращения модели к клиенту по имени и отчеству или всех ее ответов с конкретной начальной фразой. От качества обучения модели и степени понимания инструкции зависит соответствие ответов заданному промпту.

Переведи на английский стих:
Эх, лапти мои, Четыре оборки, Хочу - дома заночую, Хочу - у Егорки.

 Here is the translation of the poem into English:

Oh, my bast shoes,
With four lace trims,
If I want, I'll sleep at home,
If I want, I'll stay at Yegor's.

Представь, что ты мастер-литературовед древнего английского языка. Использую подходящую старинную лексику, чтобы перевести следующий стих:
"Эх, лапти мои, Четыре оборки, Хочу - дома заночую, Хочу - у Егорки."

 Here is the translation of the poem into Old English-inspired language:

Lo, mine laced shoes,
With four-fold adornment fair,
If at home I choose to bide,
Or at Yegor's do I declare.

RAG

RAG (Retrieval Augmented Generation) — набор техник для подачи в модель дополнительных знаний, в основном через поиск релевантных текстов и их добавление в промпт. Например, модель, обученная на данных до 2023 года, не знает о фичах айфона 2025 года. Но если мы подадим ей на вход текст с описанием нового флагмана Apple — она применит знания оттуда и не выдумает своей ответ (не будет галлюцинировать). От качества обучающего корпуса модели зависит степень ее обращения к поданному тексту.







Схема RAG




Создание векторной БД (Vector DB creation)



Запрос в векторную БД (Query Retrieval)



Генерация ответа (Response Generation)



Fine-tuning

Fine-tuning — дообучение готовой LLM на целевых данных для наиболее эффективной работы над конкретной задачей. Это первый шаг при превращении LLM в Assistant LLM.

Supervised fine-tuning (SFT) — дообучение Assistant LLM на корпусе высококачественных инструкций и ответов.

Fine-tuning

- Full fine-tuning
- Parameter Efficient fine-tuning (PEFT)

Parameter Efficient fine-tuning (PEFT)

- LoRA
- QLoRA

LoRA




Figure 1: Our reparametrization. We only train A and B .

Линейный слой


$$h = Wx$$

Линейный слой после добавления обучаемых матриц A и B

$$h = Wx + BAx$$

При этом матрица W имеет размерность $[d, d]$, а матрицы A и B — размерности $[d, r]$ и $[r, d]$ соответственно, где $r \ll d$ (обычные значения d — это 8, 16, 32). Таким образом, мы обучаем только $2 * r * d$ параметров вместо $d * d$

QLoRA



Библиотеки, модели, датасеты



Hugging Face




Transformers

Фреймворки для дообучения LLM



unisloth



LLaMA-Factory
Easy and Efficient LLM Fine-Tuning

Использованные материалы

- [Русскоязычный пост о fine-tuning LLM](#)
- [Видео о дообучении LLM с помощью Unsloth](#)
- [Статья по построению RAG](#)